

2. IML

$$\ker(X) \subseteq \ker(X^T X)$$

הוכחה, נניח $v \in \ker(X)$

① ②.1

$$Xv = 0 \quad \text{כי} \quad v \in \ker(X) \quad \text{וכן} \quad v \in V$$

לכן

$$X^T X v = X^T (Xv) = X^T 0 = 0$$

$$v \in \ker(X^T X) \quad \text{לכן}$$

$$\ker(X) \supseteq \ker(X^T X) \quad \text{וכן}$$

$$X^T X v = 0 \quad \text{כי} \quad v \in \ker(X^T X) \quad \text{וכן} \quad v \in V$$

$$v^T X^T X v = v^T 0 = 0 \quad \text{לכן}$$

$$v^T X^T X v = \langle Xv, Xv \rangle = 0 \quad \text{לפי}$$

$$Xv = 0 \iff \langle Xv, Xv \rangle = 0 \quad \text{לפי הנוסחה של הסקלר}$$

$$v \in \ker(X) \quad \text{לכן}$$

$$\ker(X) = \ker(X^T X) \quad \text{וכן}$$

הוכחה

$$\therefore \ker(A)^\perp \supseteq \operatorname{Im}(A^T) \quad \text{כך נראה, נראה (2)}$$

$$\text{נניח } A^T v = y \neq 0 \quad \text{על } v \in V \quad \text{נניח}$$

$$\therefore w^T y = 0 \quad \text{כך נראה } w \in \ker(A) \quad \text{על } w \in V$$

$$w^T y = w^T A^T v = \underbrace{(Aw)^T}_{\substack{\text{אולי } \rightarrow \text{כך נראה}}} v = 0v = 0$$

$$y \in \ker(A)^\perp, \text{ אולי}$$

$$\therefore \ker(A)^\perp \subseteq \operatorname{Im}(A^T) \quad \text{כך נראה, נראה}$$

$$\text{נניח } v \in \ker(A) \quad \text{כך נראה, נראה}$$

$$v \in \ker(A) \iff Av = 0 \iff \forall u \in V \quad \langle Av, u \rangle = 0 \iff \langle v, A^T u \rangle = 0 \iff$$

$$\iff v \perp A^T u \iff v \in \operatorname{Im}(A^T)^\perp$$

$$\ker(A) = \operatorname{Im}(A^T)^\perp, \quad \text{כך נראה, נראה}$$

$$\ker(A)^\perp = \operatorname{Im}(A^T)^{\perp\perp} = \operatorname{Im}(A^T) \quad \text{כך נראה, נראה}$$

כך נראה, נראה

$$\ker(A)^\perp = \operatorname{Im}(A^T) \quad \text{כך נראה, נראה} \quad \ker(A)^\perp \subseteq \operatorname{Im}(A^T) \quad \text{כך נראה}$$



③ X היקוצצית וחסר ג'נרל $\Leftrightarrow \text{rank } X = \infty$ פירוט

או 0 פירוט.

כנסת, נגדן כי $Xw = y$ אם ורק אם y אמצע

ג'טאן y (כ $y \in \text{Im}(X)$). כלומר, נשים לב כי $y \in \text{Im}(X)$

$$y \in \text{Im}(X) \Leftrightarrow y \in \ker(X^T)^\perp \Leftrightarrow y \perp \ker(X^T)$$

↑
שאלה קצרה

$$\Leftrightarrow y \perp \ker(X^T)$$

כך נרש



הערות נוספות: $X^T X$ הפיכה

(1)

$$(X^T X)^{-1} X^T X = I_n \quad \text{כאשר } (X^T X)^{-1} \text{ קיים}$$

$$\text{לכן, עבור } X^T X w = X^T y$$

ה- $(X^T X)^{-1}$ הוא הפיכה, ולכן:

$$(X^T X)^{-1} X^T X w = (X^T X)^{-1} X^T y \iff w = (X^T X)^{-1} X^T y$$

כעת, נראה כי $X^T X$ הפיכה:

ההשעיה הראשונה, $X^T X$ היא מטריצה סימטרית

$$\ker(X^T X) = \ker(X) \quad \text{וכן } X^T y \perp \ker(X^T X)$$

באופן כללי, $X^T y \perp \ker(X)$ עבור כל y

נניח כי $X^T y \perp \ker(X)$

אם $v \in \ker(X)$ אז:

$$\langle v, X^T y \rangle = \langle Xv, y \rangle = \langle 0, y \rangle = 0$$

לכן, $X^T y \perp \ker(X)$ עבור כל y

אנחנו נגדיר $V_i = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_k \end{pmatrix}$ (a) (5) (2.2)

העמוד הראשון של המטריצה

$$V_i V_i^T = \begin{bmatrix} x_1 x_1 & x_1 x_2 & x_1 x_3 & \dots & x_1 x_k \\ x_2 x_1 & & & & \\ x_3 x_1 & & & & \\ \vdots & & & & \\ x_k x_1 & \dots & \dots & & x_k x_k \end{bmatrix}$$

באופן כללי, $V_i V_i^T$ הוא המכפלה הפנימית של העמוד הראשון של המטריצה

ρ הוא המכפלה הפנימית של העמוד הראשון של המטריצה

(b) $V \in \mathbb{R}^n$ $V = \begin{pmatrix} V_1 \\ \vdots \\ V_k \end{pmatrix}$

$\forall a_i, a_i \in \mathbb{R}$ $a_1 V_1 + a_2 V_2 + \dots + a_k V_k = V = \sum_{i=1}^k a_i V_i$ (אנחנו)

לכן

$$\rho_V = \left(\sum_{i=1}^k V_i V_i^T \right) V = \sum_{i=1}^k V_i V_i^T V = \sum_{i=1}^k V_i (V_i^T V) =$$

$$= \sum_{i=1}^k V_i \left(V_i^T (a_1 V_1 + a_2 V_2 + \dots + a_k V_k) \right) = \sum_{i=1}^k V_i (a_1 V_i^T V_1 + a_2 V_i^T V_2 + \dots + a_k V_i^T V_k)$$

רצוי להוכיח כי $V_i^T V_j = 0$ עבור $i \neq j$

$$V_i^T V_j = \begin{cases} 0 & i \neq j \\ 1 & i = j \end{cases}$$

וכן

$$\sum_{i=1}^K V_i (a_i V_i^T V_1 + a_2 V_i^T V_2 + \dots + a_K V_i^T V_K) = \sum_{i=1}^K V_i (a_i V_i^T V_i) = \sum_{i=1}^K a_i V_i = V$$

כלומר $V \in V$ כלומר V הוא וקטור במרחב V

אם V הוא וקטור במרחב V אז $V^T V = 0$

כלומר $V \in V$

$$\sum_{i=1}^K V_i (V_i^T V) = \sum_{i=1}^K 0 V_i = 0$$

כלומר $V^T V = 0$ כלומר V הוא וקטור במרחב V

כלומר $V \in V$

כלומר

$$p^2 = \sum_{i=1}^K V_i V_i^T \cdot \sum_{j=1}^K V_j V_j^T = \sum_{i=1}^K \sum_{j=1}^K V_i V_i^T V_j V_j^T$$

پہلے $V_i \cdot V_j$ کی قیمت معلوم کریں

$$V_i^T V_j = \begin{cases} 0 & i \neq j \\ 1 & i = j \end{cases}$$

$$\sum_{i=1}^n \sum_{j=1}^n \underbrace{V_i^T V_j}_{\substack{i \neq j \Rightarrow 0 \\ i = j \Rightarrow 1}} V_j^T = \sum_{i=1}^n V_i V_i^T = P$$

پھر

معلوم

$$(I - P)P = P - P^2 = P - P = 0$$

②



پھر $P^2 = P$

$$(X^T X)^{-1} X^T y = X^+ y \quad \text{ז"ש } (6) \quad (2.3)$$

רשומה במצורה SVD:

$$\begin{aligned} (X^T X)^{-1} X^T y &= \left((U \Sigma V^T)^T (U \Sigma V^T) \right)^{-1} (U \Sigma V^T)^T y = \\ &= \left(V \Sigma^T \underbrace{U^T U}_{I_n} \Sigma V^T \right)^{-1} (V \Sigma^T U^T) y = \left(V \Sigma^T \Sigma V^T \right)^{-1} (V \Sigma^T U^T) y = \end{aligned}$$

$$= V \left(\Sigma \Sigma^T \right)^{-1} V^T U^T y = V \begin{pmatrix} \frac{1}{\sigma_1^2} & & 0 \\ & \ddots & \\ 0 & & \frac{1}{\sigma_n^2} \end{pmatrix} \begin{pmatrix} \sigma_1 & & 0 \\ & \ddots & \\ 0 & & \sigma_n \end{pmatrix} U^T y =$$

\uparrow
 $A^T = A$ כן
 מתקיים כי A סימטרי

$$= V \begin{pmatrix} \frac{1}{\sigma_1} & & 0 \\ & \ddots & \\ 0 & & \frac{1}{\sigma_n} \end{pmatrix} U^T y = V \Sigma^+ U^T y = X^+ y$$

במקרה

(*) דוגמה: להאנומר בה $\sigma_i = 0$ נחלק את המכנה

$$\text{דוגמה: אם } \sigma_i = 0 \text{ אז } (\Sigma \Sigma^T)^{-1} = 0 \text{ ואז}$$

לא נחלק את המכנה.

$$\textcircled{7} \quad \text{צ"ל:} \quad X^T X \iff \text{sp}\{x_1, \dots, x_m\} = \mathbb{R}^d$$

יש לזכור, נא'ם א'ם ב' x ו'קו'ר ב' ש'חר $X^T X$ א'.

ב' ז'ד מ'ק'רר ב' ד'ס'ה, ה'ט'ר $\text{rk}(X) = \text{rk}(X^T X)$ ב'.

א'ב':

$$\implies X^T X \text{ ד'ב'ב' א'ב'ן } \text{rk}(X^T X) \text{ ש'ו'ל א'ז'ר}$$

$$\text{ד'ר'ר צ'ל } (d =) \text{ א'ב'ן } \text{rk}(X) = d \iff \text{sp}\{x_1, \dots, x_m\} = \mathbb{R}^d$$

$$\iff \text{sp}\{x_1, \dots, x_m\} = \mathbb{R}^d \iff \text{rk}(X) = d \iff \text{rk}(X^T X) = d$$

א'ר'ר ו'ב'ו'רר ש' ע'ז'ר'ר ש'ו'ל ש'ר'ס' ד'ס'רר א'ר'ר ד'ב'ב'.

$$\text{א'ב'ן } X^T X \text{ ד'ב'ב'}$$

צ'ו'רר, ב'ר'ט'ן א'ר'ר ו'ר'ט'ל.



8) X is SVD $= U \Sigma V^T$

Proof: X^T is the adjoint of X

$$① \quad XX^T X = X$$

$$② \quad X^T X X^T = X^T$$

$$③ \quad (XX^T)^T = XX^T$$

$$④ \quad (X^T X)^T = X^T X$$

Proof:

$$① \quad XX^T X = (U \Sigma V^T)(V \Sigma^T U^T)(U \Sigma V^T) = (U \Sigma V^T V \Sigma^T U^T U \Sigma V^T) = U \Sigma \Sigma^T \Sigma V^T = U \Sigma V^T = X \quad \blacksquare$$

$$② \quad X = \underbrace{(X^T)^T}_{\text{adjoint of } X^T} \quad \text{by ①} \quad \text{adjoint of } X^T \text{ is } X$$

$$\Sigma \Sigma^T = \Sigma^T \Sigma$$

$$③ \quad (XX^T)^T = (U \Sigma V^T V \Sigma^T U^T)^T = (U \Sigma \Sigma^T U^T)^T = (U \Sigma^T \Sigma U^T)^T = (U \Sigma^T I_n \Sigma U^T)^T = (U \Sigma^T V^T V \Sigma U^T)^T = ((U \Sigma^T V^T)(V \Sigma U^T))^T = (U \Sigma U^T)^T (U \Sigma^T V^T)^T = (U \Sigma V^T)(V \Sigma^T U^T) = XX^T \quad \blacksquare$$

$$④ \quad X = \underbrace{(X^T)^T}_{\text{adjoint of } X^T} \quad \text{by ③} \quad \text{adjoint of } X^T \text{ is } X$$

$$\hat{w} = x^T y$$

در این مرحله، فرض می‌کنیم که $\bar{w} \neq \hat{w}$

$$x^T (x \hat{w} - y) \stackrel{\textcircled{1}}{=} x^T (x x^T y - y) \stackrel{\textcircled{2}}{=} x^T (x x^T)^T b - x^T b =$$

$$= (x x^T x)^T b - \underset{\textcircled{3}}{x^T b} = x^T b - x^T b = 0 \quad (*)$$

در این مرحله، فرض می‌کنیم که $\bar{w} \neq \hat{w}$

$$\|x \bar{w} - y\|^2 = \|x \bar{w} - x \hat{w} + x \hat{w} - y\|^2 = \|x(\bar{w} - \hat{w}) + x \hat{w} - y\|^2 =$$

$$= \|x(\bar{w} - \hat{w})\|^2 + \|x \hat{w} - y\|^2 + 2(x(\bar{w} - \hat{w}))^T (x \hat{w} - y) =$$

$$= \|x(\bar{w} - \hat{w})\|^2 + \|x \hat{w} - y\|^2 + 2(\bar{w} - \hat{w})^T \underset{\textcircled{4}}{x^T (x \hat{w} - y)} \stackrel{(*)}{=} \|x(\bar{w} - \hat{w})\|^2 + \|x \hat{w} - y\|^2 \geq \|x \hat{w} - y\|^2 \quad \textcircled{\#}$$

در این مرحله، فرض می‌کنیم که $\bar{w} \neq \hat{w}$

$$\langle \hat{w}, \bar{w} - \hat{w} \rangle = \hat{w}^T (\bar{w} - \hat{w}) = (x^T y)^T (\bar{w} - \hat{w}) \stackrel{\textcircled{1}}{=} (x^T x x^T y)^T (\bar{w} - \hat{w})$$

$$= ((x^T x)(x^T y))^T (\bar{w} - \hat{w}) = (x^T y)^T \underset{\textcircled{2}}{(x^T x)^T} (\bar{w} - \hat{w}) \stackrel{\textcircled{3}}{=} (x^T y)^T x^T x (\bar{w} - \hat{w}) =$$

$$= (x^T y)^T \left(\underset{\textcircled{4}}{x^T x \bar{w}} - \underset{\textcircled{5}}{x^T x \hat{w}} \right) = (x^T y)^T (x^T y - x^T x x^T y) \stackrel{\textcircled{6}}{=} (x^T y)^T (x^T y - x^T y) = 0 \quad \textcircled{\star}$$

$\because \bar{w} \neq \hat{w}$ \Rightarrow $\bar{w} - \hat{w} \neq 0$ \Rightarrow $\bar{w} - \hat{w} \neq 0$

$$\|\bar{w}\|^2 = \|\hat{w} + \bar{w} - \hat{w}\|^2 = \|\hat{w}\|^2 + \|\bar{w}\|^2 + 2\hat{w}^T(\bar{w} - \hat{w}) = \|\hat{w}\|^2 + \|\bar{w}\|^2 + 0 = \|\hat{w}\|^2$$



~~Q.E.D.~~

חלק מעשי:

(1) - החלטתי להוריד את הפיצ'רים הבאים:

`['id', 'sqft_lot15', 'sqft_living15', 'long', 'lat', 'date']`

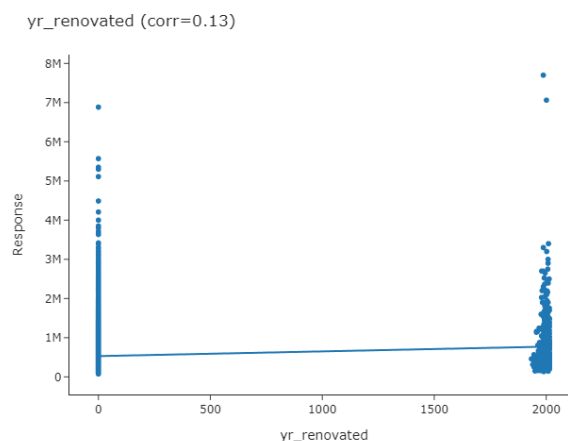
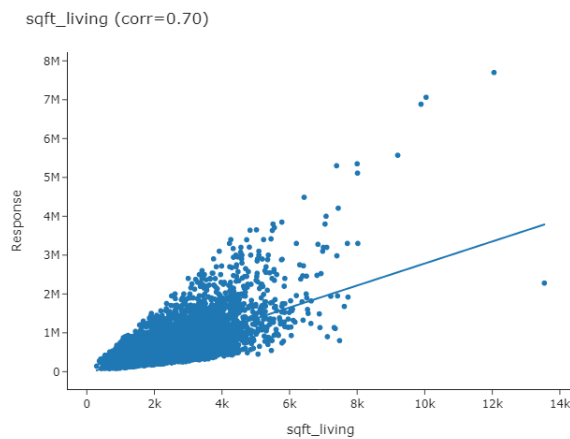
זאת כיוון שלהערכתי הם לא היו רלוונטים לניבוי המחיר הצפוי ל הבית

- לדעתי הפיצ'ר הקטגורי היחיד היה זיפקוד, זאת כיוון שהוא מעיד על מיקום בית שזוהי קטגוריה ולכן היה צורך להשתמש ב `get_dummies` בכדי שניתן יהיה להשתמש בפיצ'ר זה.

- עבור דאטא לא זמין או לא הגיוני (מס' חדרים קטן מ0 וכו') בסט האימון הסרתי לגמרי. בסט הבחינה אני חישבתי את הממוצע לכל עמודה בסט האימון ובמקומות הלא זמינים בסט הבחינה הכנסתי את הממוצע של אותה עמודה.

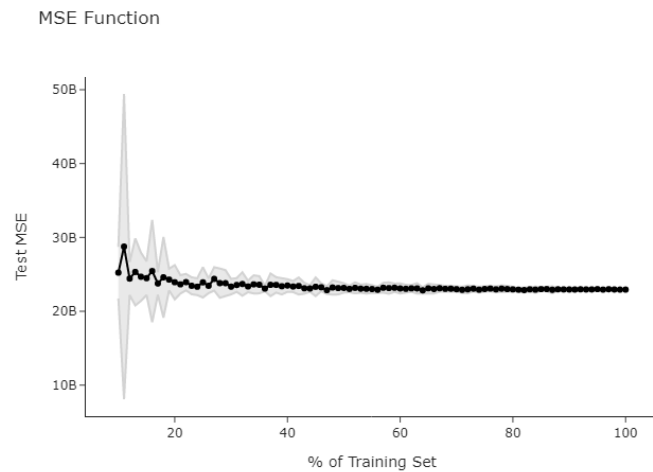
- בנוסף, ווידאתי על כל אחד מהשדות שהוא מספרי ובר חישוב

(2)



הסקתי האם הם מועילים או לא בכך שניסיתי לראות אם יש צפיפות נקודות גבוהה יותר סביב גרף הפונקציה ככל שמתקרבים אליה ואיש כמות יחסית קטנה של נקודות שרחוקות מהגרף.


(4)




ניתן לראות כי ככל שכמות הדגימות גדלה גם השגיאה של הדגימות קטנה וגם השונות קטנה

חלק שני:

(2)




לפי הגרף, נראה כי דרגת הפונקציה תהיה גדולה מ2, נראה כאילו 3 מתאר את דרגת הפונקציה של הגרף.



נראה שעבור החודשים 7-8 תהיה יכולת הניבוי הטובה ביותר, ואילו בחודשים 3-4 השונות הגבוהה ביותר ולכן גם יכולת הניבוי טובה פחות.


(3)

Average Monthly Temperature by Country



ניתן לראות כי המדינות שונות ביניהן בגרף המתאר את ממוצע המעלות. ניתן לראות לדוגמא שבדרום אפריקה חודשי החורף והקיץ הפוכים מהולנד. המדינה שהמודל של ישראל יתאר בצורה הטובה ביותר היא ככל הנראה ירדן, עד כדי כמעט חפיפה בהמודל של ישראל יתאר בצורה הטובה ביותר היא ככל הנראה ירדן, עד כדי כמעט חפיפה בחודשים 5-6. אך בחודשים אחרים (1,12) המודל הישראלי לא מתאר טוב את הטמפרטורה בירדן (בחודש 12 המודל הישראלי ינבא טוב יותר את דרום אפריקה מאשר את ירדן) אם כי צורת המודל עדיין יחסית דומה.

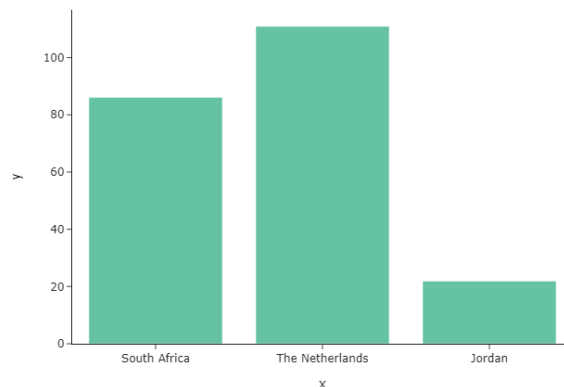
(4)



הערכים (בהתאמה): [22.26 7.38 3.37 2.82 2.67 7.84 17.17 32.11 32.11 32.11]

ניתן לראות כי ה-k המתאים ביותר הוא 5 עם שגיאה של 2.67. אך עם זאת גם עבור k של 3 נקבל שגיאה יחסית נמוכה ובהבדל לא גדול מ-5

(5)



המודל שמתאים בצורה הטובה ביותר למודל הישראלי הוא כפי שנאמר בשאלה 3, ירדן. הגיוני להניח כי חלק מזה הוא בגלל הקרבה בין המדינות