

3. פרק 3 IML

$$\arg \min_{(w,b)} \|W\|^2$$

3.1

1

2.1

$$\text{s.t. } \forall i \quad y_i (\langle W, x_i \rangle + b) \geq 1$$

כלל

$$\arg \min \frac{1}{2} V^T Q V + a^T V$$

$$\text{s.t. } AV \leq d$$

פרק 3

$$\|W\|^2 = W^T I_W W$$

כלל

כלל

$$y_i (\langle W, x_i \rangle + b) \geq 1 \iff y_i W^T x_i + y_i b \geq 1 \iff$$

$$\iff y_i x_i^T W + y_i b \geq 1$$

כלל, כלל

$$A' = \begin{bmatrix} (y_1 X_1^T) & y_1 \\ (y_2 X_2^T) & y_2 \\ \vdots & \vdots \\ (y_n X_n^T) & y_n \end{bmatrix}, \quad V = \begin{pmatrix} w \\ b \end{pmatrix}$$

נגדל

$$\begin{bmatrix} y_1 X_1^T w + y_1 b \\ y_2 X_2^T w + y_2 b \\ \vdots \\ y_n X_n^T w + y_n b \end{bmatrix} = A' V \geq 1 \quad \Leftrightarrow$$

$$\Leftrightarrow -A' V \leq -1$$

$$d = \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}, \quad A = -A', \quad V = V \quad \text{נגדל}$$

$$A V < d \quad \text{ל} \quad \text{נגדל} \quad \text{נגדל}$$

$$w \quad \text{ל} \quad \text{נגדל} \quad \text{נגדל}$$

$$\|w\|^2 = w^T w = w^T I_n w \quad \text{ל} \quad \text{נגדל}$$

$$M_{n+1 \times n+1} \ni Q = \begin{bmatrix} I_n \\ 0 \end{bmatrix} \quad \text{רצף}$$

$$\arg \min \|w\|^2 \quad \text{כ} \quad G_{\text{רק}} \quad a = 0_V \quad \rho < 1$$

$$\arg \min V^T Q V + a^T V \quad \text{רצף}$$

רצף

$$y_i \langle w, x_i \rangle > 1 \quad \text{כ} \quad \rho < 1 \quad \text{רצף} \quad (2)$$

$$y_i \langle w, x_i \rangle > 1 \quad \text{כ} \quad \rho < 1 \quad \text{רצף}$$

ה' בחור א' בסוף  
ה' בחור א' בסוף

$$\sum_i \xi_i \quad \text{כ} \quad \rho < 1 \quad \text{רצף}$$

$$\xi_i = l^{\text{hinge}}(y_i \langle w, x_i \rangle)$$

$$y_i \langle w, x_i \rangle < 1 \quad \text{כ} \quad \rho < 1 \quad \text{רצף}$$

$$y_i \langle w, x_i \rangle \geq 1 - \xi_i \Leftrightarrow y_i \langle w, x_i \rangle - 1 \geq -\xi_i \Leftrightarrow$$

$$\Leftrightarrow -y_i \langle w, x_i \rangle + 1 \leq \xi_i \Leftrightarrow 1 - y_i \langle w, x_i \rangle \leq \xi_i \Leftrightarrow l^{\text{hinge}}(y_i \langle w, x_i \rangle) \leq \xi_i$$

$$\sum_i \xi_i \quad \text{כ} \quad \rho < 1 \quad \text{רצף}$$

$$f_i = l^{\text{hinge}}(y_i \langle w, x_i \rangle) \quad \text{פונקציה}$$

כלומר, הפונקציה  $f_i$  מודדת את המרחק בין הנקודה  $x_i$  לבין המישור ההפרדה.

$$f_i = l^{\text{hinge}}(y_i \langle w, x_i \rangle) \quad \text{פונקציה} \quad \frac{1}{n} \sum f_i \quad \text{ערך אמצעי}$$

אם  $\lambda = 0$  soft SVM הפונקציה  $f_i$  היא פונקציה הריבועית.

$$\arg \min_{w, \{f_i\}} \frac{\lambda}{2} \|w\|^2 + \frac{1}{n} \sum_i l^{\text{hinge}}(y_i \langle w, x_i \rangle)$$

ערך



2.2

③ א) נניח שיש לנו  $N$  דוגמאות, נקרא בהן  $x_1, \dots, x_N$

הן  $G$  קבוצת  $x_i \in \mathbb{R}$  ו- $y_i \in \{1, \dots, K\}$

"נניח שהפרמטרים  $\mu_k, \sigma_k^2$  ידועים מראש"

נניח  $\pi = (\pi_1, \dots, \pi_K)$  ו- $\pi_k \in [0, 1]$

Naive Bayes, נניח  $x_i | y_i = k \sim N(\mu_k, \sigma_k^2)$

$y \sim \text{Mult}(\pi)$  ו- $\sum_{i=1}^K \pi_i = 1$

נניח  $\pi = (\pi_1, \dots, \pi_K)$  ו- $\pi_k \in [0, 1]$

נניח:

$$L(\Theta | x, y) = f_{(x, y) | \Theta} \left( (x_i, y_i)_{i=1}^m \right) = \prod_{i=1}^m f_{x, y | \Theta} (x_i, y_i) =$$

$$= \prod_{i=1}^m f_{x | y=y_i} (x_i) \cdot f_{y | \Theta} (y_i) = \prod_{i=1}^m N(x_i | \mu_{y_i}, \sigma_{y_i}^2) \text{Mult}(y_i | \pi)$$

log-likelihood נניח  $\log$

$$\ell(\Theta | (x, y)) = \log \left( \prod_{i=1}^m N(x_i | \mu_{y_i}, \sigma_{y_i}^2) \text{Mult}(y_i | \pi) \right) =$$

$$\begin{aligned}
&= \sum_{i=1}^n \log \left( \mathcal{N}(x_i | \mu_{y_i}, \sigma_{y_i}^2) \right) + \log(\text{mult}(y_i | \pi)) = \\
&= \sum_{i=1}^n \log \left( \frac{1}{\sqrt{2\pi}\sigma_{y_i}} \exp \left( -\frac{(x_i - \mu_{y_i})^2}{2\sigma_{y_i}^2} \right) \right) + \log(\pi_{y_i}) = \\
&= \sum_{i=1}^n -\frac{1}{2} \log(2\pi) - \frac{1}{2} \log(\sigma_{y_i}^2) - \frac{(x_i - \mu_{y_i})^2}{2\sigma_{y_i}^2} + \log(\pi_{y_i}) = \\
&= -\frac{n}{2} \log(2\pi) + \left( \sum_{i=1}^n -\frac{1}{2} \log(\sigma_{y_i}^2) - \frac{(x_i - \mu_{y_i})^2}{2\sigma_{y_i}^2} + \log(\pi_{y_i}) \right) = (*)
\end{aligned}$$

נניח  $\pi_k$  - הסיכוי ש- $y_i = k$  (כלומר  $\pi_k = P(y_i = k)$ )

נניח  $\sigma_k^2$  - הסיכוי ש- $x_i = k$  (כלומר  $\sigma_k^2 = P(x_i = k)$ )

נניח  $\mu_k$  - הסיכוי ש- $x_i = k$  (כלומר  $\mu_k = P(x_i = k)$ )

$$(*) = -\frac{n}{2} \log(2\pi) + \left( \sum_{k=1}^K -\frac{n_k}{2} \log(\sigma_k^2) - \frac{1}{2\sigma_k^2} \left( \sum_{y_i=k} (x_i - \mu_k)^2 + n_k \log(\pi_k) \right) \right)$$

נניח  $\pi_k$  - הסיכוי ש- $y_i = k$  (כלומר  $\pi_k = P(y_i = k)$ )

$\sum_{k=1}^K \pi_k = 1$  ו- $k \in [K]$

נניח  $g(\pi) = \sum \pi_k - 1$

לכל  $\Theta$  נמצא log-likelihood א. נרצה, (#)

$$\exists \lambda \in \mathbb{R} \text{ s.t. } \nabla l(\Theta | x, y) = \lambda \nabla g(\tau^0)$$

כל  $l(\Theta | x, y)$  נמצא נגזרת. נרצה  $\tau^0$


נמצא  $\tau$  נגזרת,  $\tau$  נמצא

נמצא  $\tau$  נגזרת,  $\tau$  נמצא  $\sum_{k=1}^K n_k \log(\tau_k)$


$$\nabla l(\Theta | x, y) = \left( \frac{n_1}{\tau_1}, \frac{n_2}{\tau_2}, \dots, \frac{n_K}{\tau_K} \right)^T$$

$$\nabla g(\tau^0) = (1, 1, \dots, 1)^T \text{ נמצא } g(\tau) \text{ נמצא}$$

$$\nabla l(\Theta | x, y) = \lambda \nabla g(\tau^0) \text{ נמצא}$$




$$\begin{pmatrix} \frac{n_1}{\tau_1} \\ \vdots \\ \frac{n_K}{\tau_K} \end{pmatrix} - \begin{pmatrix} \lambda \\ \vdots \\ \lambda \end{pmatrix} = 0$$



$$\forall k \in K \quad \lambda = \frac{n_k}{\tau_k}$$





$$\forall k \in K \quad \pi_k^* = \frac{n_k}{\lambda}$$

$$\text{כך נקבל} \quad \sum_{k=1}^K \pi_k^* = 1 \quad \text{על מנת}$$

$$\sum_{k=1}^K \pi_k^* = \sum_{k=1}^K \frac{n_k}{\lambda} = \frac{1}{\lambda} \sum_{k=1}^K n_k = 1 \Leftrightarrow \sum_{k=1}^K n_k = \lambda$$

$$\text{כלומר:} \quad \text{כך נקבל} \quad \left( \sum \mathbb{1}_{\{y_i=k\}} \right) n_k \quad \text{כך נקבל}$$

$$\sum_{i=1}^m 1 = \lambda \Rightarrow \lambda = m \quad \text{כלומר}$$

$$\pi_k^{MLE} = \frac{n_k}{m} \quad \text{כך נקבל}$$

$$k \in K \quad \text{כל} \quad \sigma_k^2, \mu_k \quad \text{כל} \quad \text{כל} \quad \text{כל}$$

$$\text{כל} \quad \mu_k \quad \text{כל} \quad \oplus \quad \text{כל} \quad \text{כל}$$

$$\sum_{\{i|y_i=k\}} (x_i - \mu_k) = 0 \Rightarrow \left( \sum x_i \right) - n_k \cdot \mu_k = 0 \Rightarrow \sum x_i = n_k \mu_k \Rightarrow$$

$$\Rightarrow \underline{\mu_k^{MLE} = \frac{\sum_{\{i|y_i=k\}} x_i}{n_k}}$$

$$\text{כלומר:} \quad \text{כל} \quad \text{כל} \quad \sigma_k^2 \quad \text{כל} \quad \text{כל} \quad \text{כל}$$



$$-\frac{n}{2\sigma_k^2} - \frac{1}{2(\sigma_k^2)^2} \left( \sum_{\{i|y_i=k\}} (x_i - \mu_k)^2 \right) \Rightarrow \underline{(\sigma_k^2)^{MLE} = \frac{1}{n_k} \sum_{\{i|y_i=k\}} (x_i - \mu_k)^2}$$

ⓑ) כיוון שכל  $x_i$  קשור ל  $y_i$  ולכן נבדוק

נבדוק את המרחב של  $y_i$  ונראה שיש לנו

המרחב של  $y_i$  הוא  $\{1, 2, 3, 4, 5\}$  וזהו המרחב

של  $x_i$  והמרחב של  $x_i$  הוא  $\mathbb{R}$  וזהו המרחב

של  $y_i$  ונראה שיש לנו  $\mathbb{R}$  וזהו המרחב

של  $x_i$  והמרחב של  $x_i$  הוא  $\mathbb{R}$  וזהו המרחב

$$L(\Theta | x, y) = \prod_{i=1}^n f_{x|y=y_i}(x_i) f_{y|\Theta}(y_i) = \prod_{i=1}^n \text{Mult}(y_i | \pi) \cdot \mathcal{N}(x_i | \mu_{y_i}, \Sigma_{y_i}) =$$

$$= \prod_{i=1}^n \text{Mult}(y_i | \pi) \cdot \prod_{j=1}^d \mathcal{N}(x_{i,j} | \mu_{y_i,j}, \sigma_{y_i,j}^2) \Rightarrow$$

$$\Rightarrow l(\Theta | x, y) = \sum_{i=1}^n \left( \log(\text{Mult}(y_i | \pi)) + \sum_{j=1}^d \log(\mathcal{N}(x_{i,j} | \mu_{y_i,j}, \sigma_{y_i,j}^2)) \right)$$

נניח שיש לנו  $K \in [K]$  קטגוריות,  $y_i$  הוא המיון של  $x_i$ :

$$\sum_{k=1}^K \left( n_k \log(\pi_k) + \sum_{i=1}^m \sum_{j=1}^J \mathbb{1}_{[y_i=k]} \cdot \log(N(x_{i,j} | \mu_{k,j}, \sigma_{k,j}^2)) \right)$$

כדי למצוא את הערכים המינימום של  $\sigma_{k,j}^{MLE}$ ,  $\mu_{k,j}^{MLE}$ ,  $\pi_k^{MLE}$  נשתמש בשיטת הריבועים הקטנים.

אם נסתכל על המשוואה  $\frac{\partial}{\partial \mu_{k,j}} \log(N(x_{i,j} | \mu_{k,j}, \sigma_{k,j}^2)) = 0$  נקבל:

$$\frac{\partial}{\partial \mu_{k,j}} \log(N(x_{i,j} | \mu_{k,j}, \sigma_{k,j}^2)) = 0 \Rightarrow \frac{1}{\sigma_{k,j}^2} (x_{i,j} - \mu_{k,j}) = 0$$

$$\underline{\left( \sigma_{k,j}^2 \right)^{MLE} = \frac{1}{n_k} \sum_{\{i|y_i=k\}} (x_{i,j} - \mu_{k,j})^2}$$

$$\underline{\mu_{k,j}^{MLE} = \frac{\sum_{\{i|y_i=k\}} x_{i,j}}{n_k}}$$

$$\underline{\pi_k^{MLE} = \frac{n_k}{m}}$$

4) a) נניח כי יש לנו נתונים, נרצה למצוא את ההסתברות

המקסימלית, כלומר, נרצה למצוא את ההסתברות המקסימלית

המקסימלית, כלומר, נרצה למצוא את ההסתברות המקסימלית

$$L(\theta | X, y) = \prod_{i=1}^n f_{X|Y=y_i}(x_i) f_{Y|\theta}(y_i) = \prod_{i=1}^n \text{Poi}(x_i | \lambda_{y_i}) \cdot \text{Poi}(y_i | \pi) \Rightarrow$$

$$\xrightarrow{\log} \sum_{i=1}^n \log \left( \frac{\lambda_{y_i}^{x_i} \exp(-\lambda_{y_i})}{x_i!} \right) + \log(\pi_{y_i}) = \sum_{i=1}^n x_i \log(\lambda_{y_i}) - \lambda_{y_i} - \log(x_i!) + \log(\pi_{y_i}) =$$

$$\sum_{k=1}^K \left( \sum_{\substack{i=1 \\ y_i=k}}^n (x_i \log(\lambda_k)) - n_k \lambda_k + n_k \log(\pi_k) \right) - \sum_{i=1}^n \log(x_i!)$$

$$\left( \frac{1}{n_k} \sum_{\substack{i=1 \\ y_i=k}}^n x_i \right) - n_k \quad \text{כאשר } n_k \text{ הוא מספר ה} \quad \text{כאשר } n_k \text{ הוא מספר ה}$$

$$\lambda_{1k}^{MLE} = \frac{1}{n_k} \sum_{\substack{i=1 \\ y_i=k}}^n x_i = \frac{1}{n_k} \sum_{i=1}^n \mathbb{1}_{[y_i=k]} x_i \quad \text{כאשר } n_k \text{ הוא מספר ה}$$

כאשר  $n_k$  הוא מספר ה, כלומר, מספר ה

$$\pi_k^{MLE} = \frac{n_k}{n} \quad \text{כאשר } n_k \text{ הוא מספר ה}$$

b) נניח כי יש לנו נתונים, נרצה למצוא את ההסתברות המקסימלית

המקסימלית, כלומר, נרצה למצוא את ההסתברות המקסימלית

$$L(\Theta | X, y) = \prod_{i=1}^m \left( \prod_{j=1}^K \text{poi}(x_{i,j} | \lambda_{y_i,j}) \cdot \text{mult}(y_i | \pi) \right) \Rightarrow$$

$$\Rightarrow l(\Theta | X, y) = \sum_{i=1}^m \left( \sum_{j=1}^K \log(\text{poi}(x_{i,j} | \lambda_{y_i,j})) + \log(\text{mult}(y_i | \pi)) \right)$$

: log → log 21 → 2'22 , K → 1; 1 2 2 2 2 2 2 2 2 2


$$\sum_K \left( \sum_{j=1}^K \left( \sum_{\substack{i=1 \\ y_i=K}}^m (x_{i,j} \log(\lambda_{K,j})) - n_{K,j} \lambda_{K,j} \right) + n_K \log(\pi_K) \right) + \sum_{i=1}^m \sum_{j=1}^K \log(x_{i,j}!)$$

: 1/522 בן 1202 , 2222 , 22 22 22 22 22 22 22 22 22 22

$$\lambda_{K,j}^{MLE} = \frac{1}{n_K} \sum_{i=1}^m \mathbb{1}_{[y_i=K]} x_{i,j} \quad , \quad \pi_K^{MLE} = \frac{n_K}{m}$$

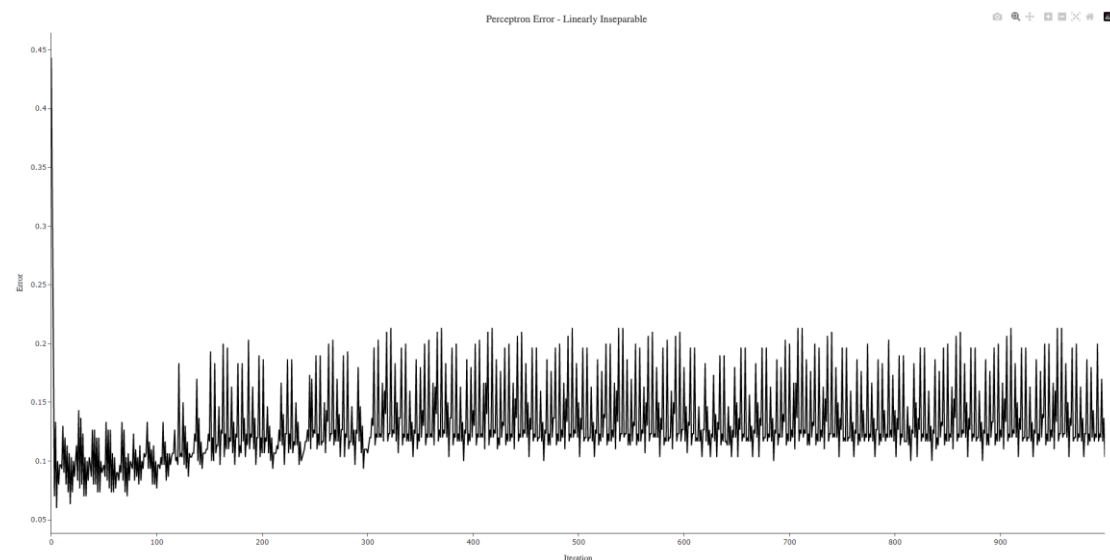
(3.1

(1



אנו יכולים ללמוד מהגרף כי ככל שכמות האיטרציות גדלה כך רמת הדיוק משתפרת, כיוון שבכל איטרציה האלגוריתם משפר את  $W$  שלו, אנו יכולים לראות כי השגיאות החריגות (השפיצים) הולכות וקטנות עד שהשגיאה מתאפסת.

(2



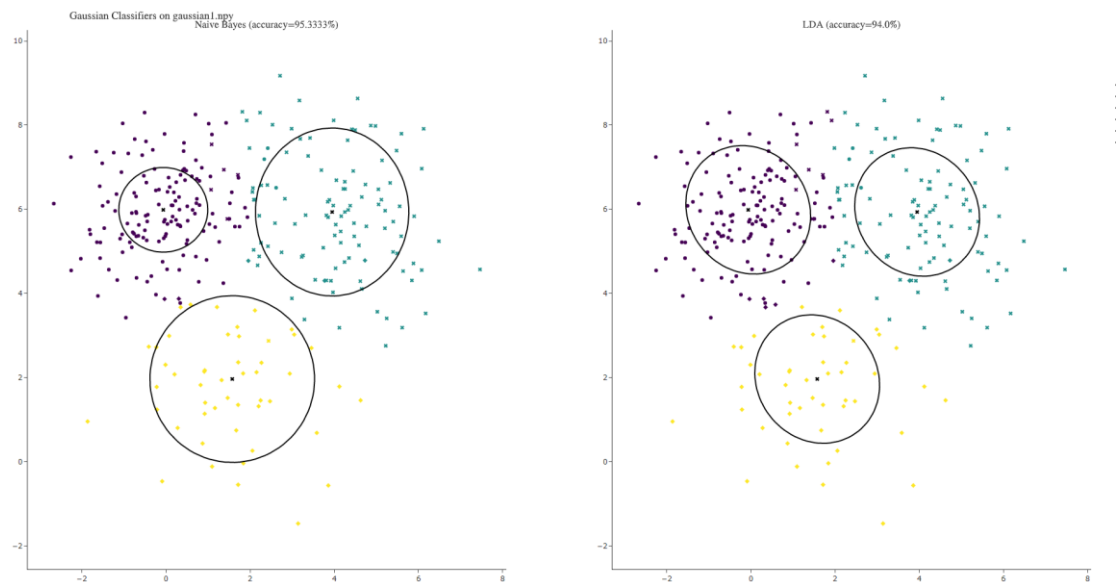
מכיוון שהפרספטרון מניח שקיימת הפרדה ליניארית לדגימות, הוא מתקשה בעיבוד דאטה שלא ניתן להפרדה ליניארית.

נוכל לשים לב כי האלגוריתם הגיע למספר האיטרציות המקסימלי שאפשרנו לו (1000 איטרציות) ועדיין לא הגיע לשגיאה שהיא 0, האלגוריתם ממשיך לחפש את ה- $W$  הנכון, וכל שינוי שלו לדגימה

מסויימת גורר סטיה על דגימה אחרת, לכן יוכל להמשיך לרוץ לנצח, זאת בניגוד למידע בר ההפרדה משהשאלה הקודמת שלאחר 52 איטרציות כבר מצא על-מישור מפריד אופטימלי לדגימות.


(3.2

(1



ניתן ללמוד מהגרף כי שני המודלים השיגו תוצאות טובות ולכן ניתן להניח כי הדגימות מתפלגות נורמלית עם שונות נמוכה

(2



מהגרף ניתן ללמוד כי לדגימות יש שונות יחסית גבוהה ושונות משותפת משמעותית. לכן עבור הדאטה הנ"ל ניתן לראות כי מודל ה LDA השיג תוצאות טובות באופן ניכר מה NAIVE BAYES ולכן נעדיף להשתמש בו.