

(16/10/21)

Prove that following Hard-SVM optimization problem is Quadratic Programming Problem?

(1)

$$\arg \min \|w\|^2 \quad \text{s.t.} \quad \forall_i y_i (\langle w, x_i \rangle + b) \geq 1 \quad (1)$$

That is, find matrices Q and A and vectors a and b s.t the above problem can be written in the following format

$$\arg \min_{V \in \mathbb{R}^n} \frac{1}{2} V^T Q V + \bar{a}^T V \quad \text{s.t.} \quad AV \leq d \quad (2)$$

Hint: Observe that $\|w\|^2 = w^T I w$

$$\forall_i y_i (\langle w, x_i \rangle + b) \geq 1 \Leftrightarrow -y_i x_i^T w - y_i b \leq -1 \Leftrightarrow$$

$$\begin{pmatrix} -y_1 x_1^T & \dots & -y_1 \\ \vdots & & \vdots \\ -y_m x_m^T & \dots & -y_m \end{pmatrix} w - y_i b \leq -1$$

Q21 NC1, PROCK & 11(1) 11(2) a^T NC 11(2) PROCK (2)
 $\arg \min_{V \in \mathbb{R}^n} \frac{1}{2} V^T Q V + \bar{a}^T V \quad \text{s.t.} \quad AV \leq d$ (3)

consider the Soft-SVM optimization problem,

(2)

$$\arg \min_{w \in \mathbb{R}^n} \frac{1}{2} \|w\|^2 + \frac{1}{m} \sum_i \xi_i \quad \text{s.t.} \quad \forall_i y_i (\langle w, x_i \rangle + b) \geq 1 - \xi_i \quad \xi_i \geq 0 \quad (3)$$

Denote the hinge-loss functions as $\ell^{\text{hinge}}(a) = \max(0, 1-a)$.
 Show that the soft-SVM optimization problem is equivalent to the following unconstrained optimization problems

$$\arg \min_{w, \{\xi_i\}} \frac{1}{2} \|w\|^2 + \frac{1}{m} \sum_i \ell^{\text{hinge}}(y_i \{w, x_i\}) \quad (4)$$

$$\begin{aligned} \arg \min_{w, \{\xi_i\}} \quad & \frac{1}{2} \|w\|^2 + \frac{1}{m} \sum_i \xi_i \\ \text{s.t.} \quad & \xi_i \geq 1 - y_i \{w, x_i\} \\ & \xi_i \geq 0 \end{aligned}$$

וכאן $\xi_i = \ell^{\text{hinge}}(y_i \{w, x_i\}) = \max(0, 1 - y_i \{w, x_i\})$

אם $y_i \{w, x_i\} > 1$ אז $\xi_i = 0$
 אם $y_i \{w, x_i\} \leq 1$ אז $\xi_i = 1 - y_i \{w, x_i\}$

(3)

The Gaussian Naive Bayes Classifier assumes a multinomial prior and independent feature-wise Gaussian likelihoods

$$\begin{aligned} y &\sim \text{Multinomial}(\pi) \\ x_i | y = k &\sim N(\mu_{k,i}, \sigma_{k,i}^2) \end{aligned} \quad (6)$$

for π a probability vector $\pi \in [0,1]^K$, $\sum \pi_j = 1$.

(a) Suppose $x \in \mathbb{R}$ (i.e. each sample has a single feature). Given a training set $\{(x_i, y_i)\}_{i=1}^m$ fit a Gaussian Naive Bayes classifier solving (5) under assumptions (6). Fitting means finding the expressions for the maximum likelihood estimators.

אם $x \in \mathbb{R}$ אז $\mu_{k,i} = \mu_k$ ו- $\sigma_{k,i}^2 = \sigma_k^2$

$$\arg \max_{\pi, \mu, \sigma} \prod_{i=1}^m f_{X|Y}(x_i | y_i) \cdot f_Y(y_i) = \prod_{k=1}^K \pi_k \prod_{i=1}^m \frac{1}{\sigma_k} \exp\left(-\frac{(x_i - \mu_k)^2}{2\sigma_k^2}\right) \mathbb{1}_{y_i=k}$$

לפיכך $\arg \max_{\pi, \mu, \sigma} \prod_{k=1}^K \pi_k \prod_{i=1}^m \frac{1}{\sigma_k} \exp\left(-\frac{(x_i - \mu_k)^2}{2\sigma_k^2}\right) \mathbb{1}_{y_i=k}$

אם $\pi_k = \frac{n_k}{m}$ אז $\arg \max_{\pi, \mu, \sigma} \prod_{k=1}^K \left(\frac{n_k}{m}\right) \prod_{i=1}^m \frac{1}{\sigma_k} \exp\left(-\frac{(x_i - \mu_k)^2}{2\sigma_k^2}\right) \mathbb{1}_{y_i=k}$

(6) Suppose $x \in \mathbb{R}^d$ (i.e. each sample has 2 feature).

Given a trainset $S = \{(x_i, y_i)\}_{i=1}^m$ fit a Gaussian Naive Bayes classifier solving (5) under assumptions (6). You are encouraged to use the results from (3.4).

$$\arg \max_k f_{x|y=k}(x) = \prod_{j=1}^d \pi_k \cdot \frac{1}{\sqrt{2\pi}\sigma_{x_j}} e^{-\frac{1}{2\sigma_{x_j}^2}(x - \mu_{x_j})^2}$$

The Poisson Naive Bayes classifier assumes a multinomial prior and independent per feature - wise Poisson likelihoods: $\pi \sim \text{Multinomial}(\pi)$
 $x_j | y=k \sim \text{Poi}(\lambda_{k,j})$ (7)

for π a probability vector: $\pi \in [0,1]^K, \sum \pi_j = 1$.

(a) Suppose $x \in \mathbb{R}$ (i.e. each sample has a single feature).

Given a trainset $\{(x_i, y_i)\}_{i=1}^m$ fit a Poisson Naive Bayes classifier solving (5) under assumptions (7).

$$\arg \max_k f_{x|y=k}(x) \cdot f_y(x) = \arg \max_k \pi_k \text{Poi}(\lambda_k) = \arg \max_k \pi_k \prod_{i=1}^x \frac{\lambda_k}{x_i!} e^{-\lambda_k} \Rightarrow \log(\arg \max) = \log(\pi_k) + \sum (\log \frac{\lambda_k}{x_i!} e^{-\lambda_k})$$

(6) Suppose $x \in \mathbb{R}^d$ (i.e. each sample has 2 feature). Given a trainset $S = \{(x_i, y_i)\}_{i=1}^m$ fit a Poisson Naive Bayes classifier solving (5) under assumptions (7). You are encouraged to use the results from (4.4).


$$\arg \max_k = \log(\pi_k) + \log\left(\prod_{j=1}^d \frac{\lambda_{k,j}^{x_j}}{x_j!} e^{-\lambda_{k,j}}\right)$$

301 - סוף 1

* מסיון שאנו מתוודעים להם בדרך כלל בדרך התיאורית, כלומר (המקד) כיום שהכרזה ע"א רחוקה ציגן שבאין מתכננת איך למצוא את הדיווח (היקונים) א"א הפתח שמו שלנו גורדן בהמשך א"א שבאנו מיוצר ערך ס.

* כיום פנאום שלטוניות מתקדם קודם קואופירציה סגליות מסוימות, ובכך יום שהמיקון א"א עקומ גלגול מפי' ולכן נוצר (המיקון) החדש קצת + ההפך ה-30 האסטרטגיה כמובן מדיום (המיקון) א"א אלוהם קצתים קצרה ככונה נמשך אלוהם א"א כמיה ~~המיקון~~ מלכיו הוא מפיץ למיזם אסטרטגיה

perceptron algorithm's training loss when data is Linearly Separable




* בניגוד למורה הקודם האולגוריתם לא מחנכס ואזדר
 רן כאסו קוא גניץ למספי האולגוריתם והקסומה
 גכיוון שכר המיניץ קוא נוגן לפרסדה למסומי אן
 קצרים אלו למצויים קבוצה אין זה כמסין

ואכן האולגוריתם ממשיך זמנכס דכר מסור שפרקס אל
 המיניץ קלי כמא גכולה למצוא אומק שכנה

* אין קצרים (ליא) כק שיקויים שפ סגלדמאלי (מ) $E \neq \emptyset$

* האולגוריתם ממשיך למצוא צוגמאן שצליהם היוו מוצה
 גבהמא מתן מו ובעכ קס כרז גורמ ע"א למא
 על צוגמאן אוממא

perceptron algorithm's training loss when data is Linearly Inseparable




302
180

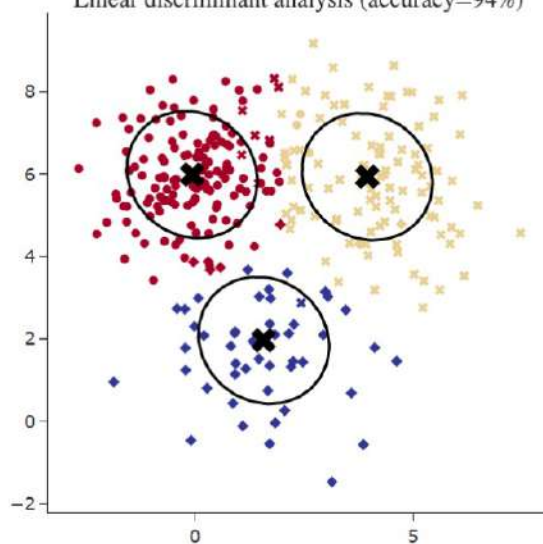
1

מחילה נ"מ. להסיר כי הדגימה קרוב המבחן אכן המבחן
בדיוק המבחן נכונה כלפי שיהא המבחן בדיוק
ערך מחזור כלשהו השמש כמות מחזור של כל
המחזור. נ"מ. למחזור כי עקוב כל מחזור בקובץ
כל אין אינדיקציה למחזור כל לפי בין המבחן
ה" features השונים של הדגימה של מחזור
הכל, מחזור ה- GMA אשר מניח כי אין ומה בין המבחן
מבחן קבוצה קבוצה טובה דומה המבחן ה- features
מחזור מחזור ה- LUA אשר מניח כי ישנה ומה בין
המבחן ה- features השונים, אך המבחן קבוצה ה" features
הכל מחזור ולכן מחזור קבוצה
סך הכל קבוצה.

Comparing Gaussian Classifiers - gaussian1 dataset
Gaussian Naive Bayes (accuracy=95.33%)



Linear discriminant analysis (accuracy=94%)

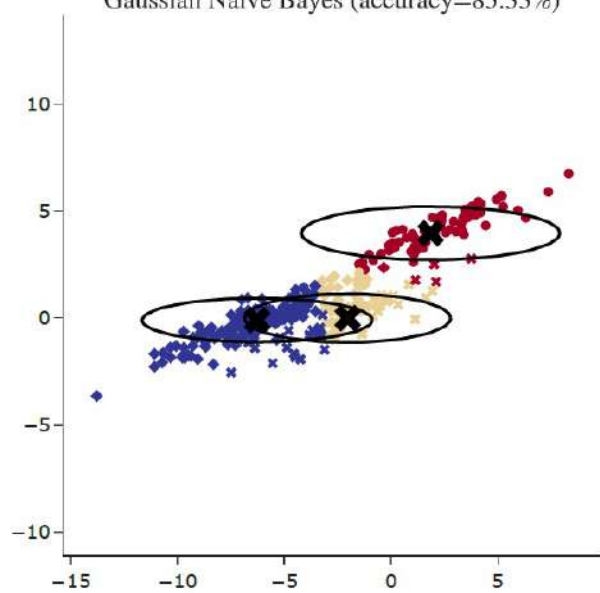


2 סוף 302

בהקרה הנ"ל ניתן לבטא כי סכום דומה שמונח (נראה)
להסברתו כך שכל מילה גלגל קוואציה בין שני ה-features,
ולכן גלגל חסר בונה.

עכשיו ניתן לבטא כי במקרה זה רמת הקונצז של מוצר
ה-LDA מפיצה פרדיקציה מוצמק לומר בצורה דומה שמות
אל המונחים לצד מוצר ה-LDA, מכיוון שהמוצר מניח כי
אין גלגל וקום כלשהו בין ההתאמות ה-features המונים.
עכשיו, גלגל עדיכיו גבוהה פרישה המוצר ה-LDA נראה
הוא אט מאמינים כי אין גלגל וקום כלשהו בין המוצר
ה-features של ההסברות ממנו נלקח המוצר.

Comparing Gaussian Classifiers - gaussian2 dataset
Gaussian Naive Bayes (accuracy=85.33%)



Linear discriminant analysis (accuracy=97%)

